DQLab

Date Fruit Classification: Comparing ML Models and Feature Selection

Bootcamp Data Analyst with SQL & Python using Google Platform

Fransisca Panggabean/PS1412

TUJUAN

Mendapatkan model *Machine Learning* terbaik yang dapat digunakan untuk klasifikasi buah Kurma, baik dengan menggunakan semua fitur, maupun menggunakan fitur yang sudah diseleksi dengan metode *feature selection*

TOOLS

Google Colab adalah layanan yang memungkinkan pengguna untuk menulis, mengedit dan menjalankan kode Python di browser

Python adalah salah satu Bahasa pemrograman yang dapat melakukan eksekusi sejumlah instruksi multi guna secara langsung dengan metoda orientasi objek

Library Python adalah Kumpulan kode yang telah dikompilasi dan dapat digunakan berulang kali dalam program. Pada proyek kali ini Library yang digunakan adalah : ***pandas, numpy, matplotlib, seaborn, xgboost, plotly.express dan scikit-learn***

DATASET

- Dataset yang digunakan untuk proyek ini adalah : Date_Fruit_Datasets.xlsx, yang diambil dari https://www.muratkoklu.com/datasets/
- Terdiri dari 898 baris, dan 35 kolom (34 kolom feature, dan 1 kolom target)

IMPORT LIBRARY

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import xgboost as xgb
import plotly.express as px


from sklearn.naive_bayes import GaussianNB
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import LabelEncoder
from sklearn.feature_selection import SelectKBest, chi2


from sklearn.metrics import f1_score, precision_score
from sklearn.metrics import accuracy_score, recall_score
from sklearn.metrics import balanced_accuracy_score
```

- Pandas dan numpy untuk manipulasi data
- Matplotlib, seaborn dan plotly express untuk visualisasi data
- xgboost, sklearn.naive_bayes, sklearn.tree, sklearn.ensemble, sklearn.linear_model, sklearn.neighbors untuk pembuatan model machine learning yang akan digunakan di proyek ini
- sklearn.model_selection untuk membagi dataset menjadi data training dan data test
- sklearn.preprocessing.StandardScaler untuk Scaling data, sedangkan LabelEncoder untuk mengubah data Label menjadi data numerik
- sklearn.metrics untuk evaluasi performance model

EXPLORATORY DATA ANALYSIS

IMPORT DAN PREVIEW DATASET

```
# import dan preview dataset
from google.colab import drive
drive.mount('/content/drive', force_remount=True)

df = pd.read_excel('/content/drive/My Drive/Date_Fruit_Datasets.xlsx')
df
```

```
Mounted at /content/drive
```

	AREA	PERIMETER	MAJOR_AXIS	MINOR_AXIS	ECCENTRICITY	EQDIASQ	SOLIDITY	CONVEX_AREA	EXTENT	ASPECT_RATIO	...	KurtosisRR	KurtosisRG	KurtosisRB	EntropyRR	EntropyRG	EntropyRB	ALLdaub4RR	ALLdaub4RG	ALLdaub4RB	Class
0	422163	2378.9080	837.8484	645.6693	0.6373	733.1539	0.9947	424428	0.7831	1.2976	...	3.2370	2.9574	4.2287	-59191263232	-50714214400	-39922372608	58.7255	54.9554	47.8400	BERHI
1	338136	2085.1440	723.8198	595.2073	0.5690	656.1464	0.9974	339014	0.7795	1.2161	...	2.6228	2.6350	3.1704	-34233065472	-37462601728	-31477794816	50.0259	52.8168	47.8315	BERHI
2	526843	2647.3940	940.7379	715.3638	0.6494	819.0222	0.9962	528876	0.7657	1.3150	...	3.7516	3.8611	4.7192	-93948354560	-74738221056	-60311207936	65.4772	59.2860	51.9378	BERHI
3	416063	2351.2100	827.9804	645.2988	0.6266	727.8378	0.9948	418255	0.7759	1.2831	...	5.0401	8.6136	8.2618	-32074307584	-32060925952	-29575010304	43.3900	44.1259	41.1882	BERHI
4	347562	2160.3540	763.9877	582.8359	0.6465	665.2291	0.9908	350797	0.7569	1.3108	...	2.7016	2.9761	4.4146	-39980974080	-35980042240	-25593278464	52.7743	50.9080	42.6666	BERHI
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
893	255403	1925.3650	691.8453	477.1796	0.7241	570.2536	0.9785	261028	0.7269	1.4499	...	2.2423	2.3704	2.7202	-25296416768	-19168882688	-18473392128	49.0869	43.0422	42.4153	SOGAY
894	365924	2664.8230	855.4633	551.5447	0.7644	682.5752	0.9466	386566	0.6695	1.5510	...	3.4109	3.5805	3.9910	-31605219328	-21945366528	-19277905920	46.8086	39.1046	36.5502	SOGAY
895	254330	1926.7360	747.4943	435.6219	0.8126	569.0545	0.9925	256255	0.7240	1.7159	...	2.2759	2.5090	2.6951	-22242772992	-19594921984	-17592152064	44.1325	40.7986	40.9769	SOGAY
896	238955	1906.2679	716.6485	441.8297	0.7873	551.5859	0.9604	248795	0.6954	1.6220	...	2.6769	2.6874	2.7991	-26048595968	-21299822592	-19809978368	51.2267	45.7162	45.6260	SOGAY
897	343792	2289.2720	823.8438	534.7757	0.7607	661.6113	0.9781	351472	0.6941	1.5405	...	2.5138	3.0369	3.0865	-31983476736	-20482514944	-21219354624	47.3454	38.6966	39.6738	SOGAY

898 rows × 35 columns

INFORMASI KOLOM, MISSING VALUES, DAN TYPE DATA

```python
# Kolom dan informasi untuk tiap kolom
df.info()
```

df.info ()

Kode ini untuk mendapatkan jumlah kolom, nama kolom, banyaknya data dan type data

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 898 entries, 0 to 897
Data columns (total 35 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   AREA            898 non-null    int64
 1   PERIMETER       898 non-null    float64
 2   MAJOR_AXIS      898 non-null    float64
 3   MINOR_AXIS      898 non-null    float64
 4   ECCENTRICITY    898 non-null    float64
 5   EQDIASQ         898 non-null    float64
 6   SOLIDITY        898 non-null    float64
 7   CONVEX_AREA     898 non-null    int64
 8   EXTENT          898 non-null    float64
 9   ASPECT_RATIO    898 non-null    float64
 10  ROUNDNESS       898 non-null    float64
 11  COMPACTNESS     898 non-null    float64
 12  SHAPEFACTOR_1   898 non-null    float64
 13  SHAPEFACTOR_2   898 non-null    float64
 14  SHAPEFACTOR_3   898 non-null    float64
 15  SHAPEFACTOR_4   898 non-null    float64
 16  MeanRR          898 non-null    float64
 17  MeanRG          898 non-null    float64
 18  MeanRB          898 non-null    float64
 19  StdDevRR        898 non-null    float64
 20  StdDevRG        898 non-null    float64
 21  StdDevRB        898 non-null    float64
 22  SkewRR          898 non-null    float64
 23  SkewRG          898 non-null    float64
 24  SkewRB          898 non-null    float64
 25  KurtosisRR      898 non-null    float64
 26  KurtosisRG      898 non-null    float64
 27  KurtosisRB      898 non-null    float64
 28  EntropyRR       898 non-null    int64
 29  EntropyRG       898 non-null    int64
 30  EntropyRB       898 non-null    int64
 31  ALLdaub4RR      898 non-null    float64
 32  ALLdaub4RG      898 non-null    float64
 33  ALLdaub4RB      898 non-null    float64
 34  Class           898 non-null    object
dtypes: float64(29), int64(5), object(1)
memory usage: 245.7+ KB
```

SUMMARY STATISTIK

```
df.describe().T.style.background_gradient(cmap = sns.color_palette("ch:s=-.2,r=.6", as_cmap=True))
```

Kode ini untuk memunculkan summary statistic untuk kolom numerik berupa : mean, std, min, kuartil (25%, 50%, 75%) dan max, secara transpose, dengan memberikan warna gradasi berdasar besar-kecilnya nilai

	count	mean	std	min	25%	50%	75%	max
AREA	898.000000	298295.207127	107245.205337	1987.000000	206948.000000	319833.000000	382573.000000	546063.000000
PERIMETER	898.000000	2057.660953	410.012459	911.828000	1726.091500	2196.345450	2389.716575	2811.997100
MAJOR_AXIS	898.000000	750.811994	144.059326	336.722700	641.068650	791.363400	858.633750	1222.723000
MINOR_AXIS	898.000000	495.872785	114.268917	2.283200	404.684375	495.054850	589.031700	766.453600
ECCENTRICITY	898.000000	0.737468	0.088727	0.344800	0.685625	0.754700	0.802150	1.000000
EQDIASQ	898.000000	604.577938	119.593888	50.298400	513.317075	638.140950	697.930525	833.827900
SOLIDITY	898.000000	0.981840	0.018157	0.836600	0.978825	0.987300	0.991800	0.997400
CONVEX_AREA	898.000000	303845.592428	108815.656947	2257.000000	210022.750000	327207.000000	388804.000000	552598.000000
EXTENT	898.000000	0.736267	0.053745	0.512300	0.705875	0.746950	0.775850	0.856200
ASPECT_RATIO	898.000000	2.131102	17.820778	1.065300	1.373725	1.524150	1.674750	535.525700
ROUNDNESS	898.000000	0.857720	0.070839	0.004800	0.827750	0.867750	0.899500	0.977300
COMPACTNESS	898.000000	0.807190	0.062175	0.041100	0.768050	0.804950	0.848875	0.968100

KOMPOSISI DATA TARGET

```
# Melihat komposisi target
jml_category = df.Class.value_counts()
jml_category
jml_category.plot(kind='bar')
```

Kode diatas untuk memunculkan komposisi data target, dan divisualisakan dalam bentuk bar-chart

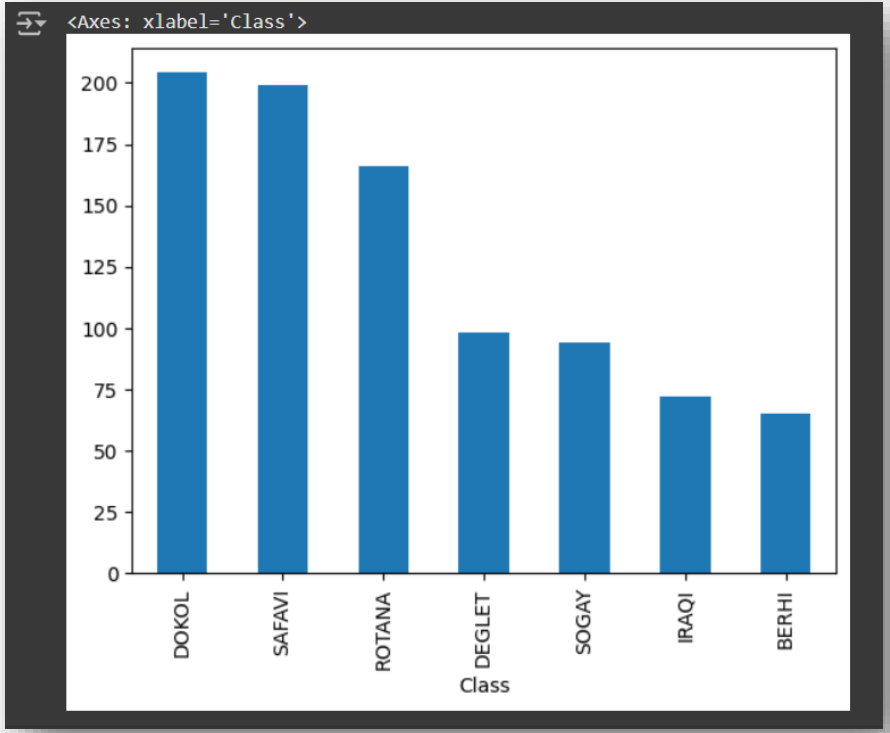

PAIRPLOT

```
[ ]  # Pairplot, dan menyimpan hasil-nya
     g = sns.pairplot(df, hue="Class")
     g.savefig("pairplot.png", dpi=300)
```

Kode diatas memunculkan visualisai pairplot untuk hubungan antara itur-fitur numerik dengan data target Class. Karena hasil dari kode diatas besar, maka hasil akan disimpan dalam colab drive. Untuk hasil-nya bisa dilihat pada attachment pairplot. Gambar disamping adalah preview dari hasil pairplott.

pairplot.png

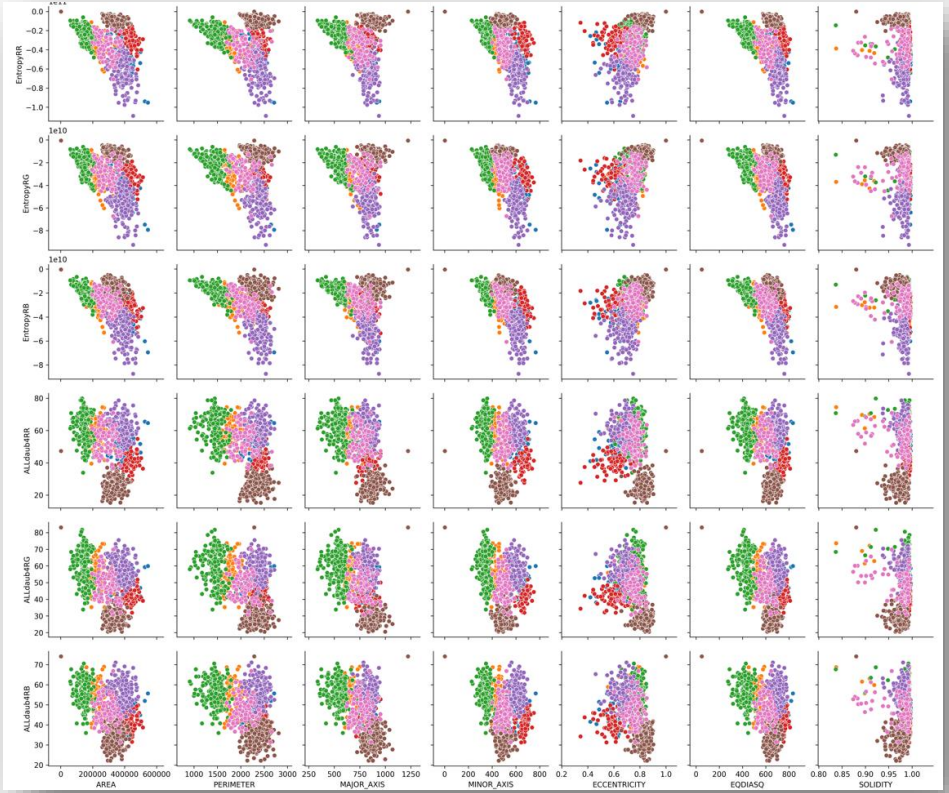

DQLab

live Class

DATA PREPROCESSING

LABEL ENCODER

```
# Melakukan pelabelan pD ata Class, untuk mempermudah proses feature selection
le = LabelEncoder()
y = le.fit_transform(df['Class'])
df['Class'] = y
df
```

Kode disamping untuk mengubah data target ‘Class’ menjadi bentuk numerical. Sehingga mempermudah dalam klasifikasi

	AREA	PERIMETER	MAJOR_AXIS	MINOR_AXIS	ECCENTRICITY	EQDIASQ	SOLIDITY	CONVEX_AREA	EXTENT	ASPECT_RATIO	...	KurtosisRR	KurtosisRG	KurtosisRB	EntropyRR	EntropyRG	EntropyRB	ALLdaub4RR	ALLdaub4RG	ALLdaub4RB	Class
	422163	2378.9080	837.8484	645.6693	0.6373	733.1539	0.9947	424428	0.7831	1.2976	...	3.2370	2.9574	4.2287	-59191263232	-50714214400	-39922372608	58.7255	54.9554	47.8400	0
	338136	2085.1440	723.8198	595.2073	0.5690	656.1464	0.9974	339014	0.7795	1.2161	...	2.6228	2.6350	3.1704	-34233065472	-37462601728	-31477794816	50.0259	52.8168	47.8315	0
	526843	2647.3940	940.7379	715.3638	0.6494	819.0222	0.9962	528876	0.7657	1.3150	...	3.7516	3.8611	4.7192	-93948354560	-74738221056	-60311207936	65.4772	59.2860	51.9378	0
	416063	2351.2100	827.9804	645.2988	0.6266	727.8378	0.9948	418255	0.7759	1.2831	...	5.0401	8.6136	8.2618	-32074307584	-32060925952	-29575010304	43.3900	44.1259	41.1882	0
	347562	2160.3540	763.9877	582.8359	0.6465	665.2291	0.9908	350797	0.7569	1.3108	...	2.7016	2.9761	4.4146	-39980974080	-35980042240	-25593278464	52.7743	50.9080	42.6666	0
	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
	255403	1925.3650	691.8453	477.1796	0.7241	570.2536	0.9785	261028	0.7269	1.4499	...	2.2423	2.3704	2.7202	-25296416768	-19168882688	-18473392128	49.0869	43.0422	42.4153	6
	365924	2664.8230	855.4633	551.5447	0.7644	682.5752	0.9466	386566	0.6695	1.5510	...	3.4109	3.5805	3.9910	-31605219328	-21945366528	-19277905920	46.8086	39.1046	36.5502	6
	254330	1926.7360	747.4943	435.6219	0.8126	569.0545	0.9925	256255	0.7240	1.7159	...	2.2759	2.5090	2.6951	-22242772992	-19594921984	-17592152064	44.1325	40.7986	40.9769	6
	238955	1906.2679	716.6485	441.8297	0.7873	551.5859	0.9604	248795	0.6954	1.6220	...	2.6769	2.6874	2.7991	-26048595968	-21299822592	-19809978368	51.2267	45.7162	45.6260	6
	343792	2289.2720	823.8438	534.7757	0.7607	661.6113	0.9781	351472	0.6941	1.5405	...	2.5138	3.0369	3.0865	-31983476736	-20482514944	-21219354624	47.3454	38.6966	39.6738	6

rows × 35 columns

MODEL TRAINING DAN EVALUATION DENGAN FEATURE SELECTION

FEATURE SELECTION DENGAN PEARSON CORRELATION

```python
corr_pearson = df.corr()

# Menampilkan matrik korelasi dalam grafik heatmap
plt.figure(figsize=(35,35))
sns.heatmap(corr_pearson, cmap="RdBu_r",annot=True)

plt.title('Correlation between Numeric Variables')
plt.show()

# Mengambil nilai absolut dari korelasi
cor_target = abs(corr_pearson["Class"])

# Memilih Fiture dengan korelasi tinggi (threshold = 0.2)
relevant_features = cor_target[cor_target>0.2]

# Mengumpulkan nama fitur
names = [index for index, value in relevant_features.items()]

# Menghapus variabel target dari hasil
names.remove('Class')
```

- Variabel corr_pearson untuk dataframe yang menggunakan metode pearson correlation
- Menampilkan matrik korelasi dalam grafik heatmap
- Mengambil nilai absolut dari korelasi
- Memilih fitur dengan korelasi tinggi (threshold = 0.2)
- Mengumpulkan nama fitur
- Menghapus variable target (‘Class’) dari hasil

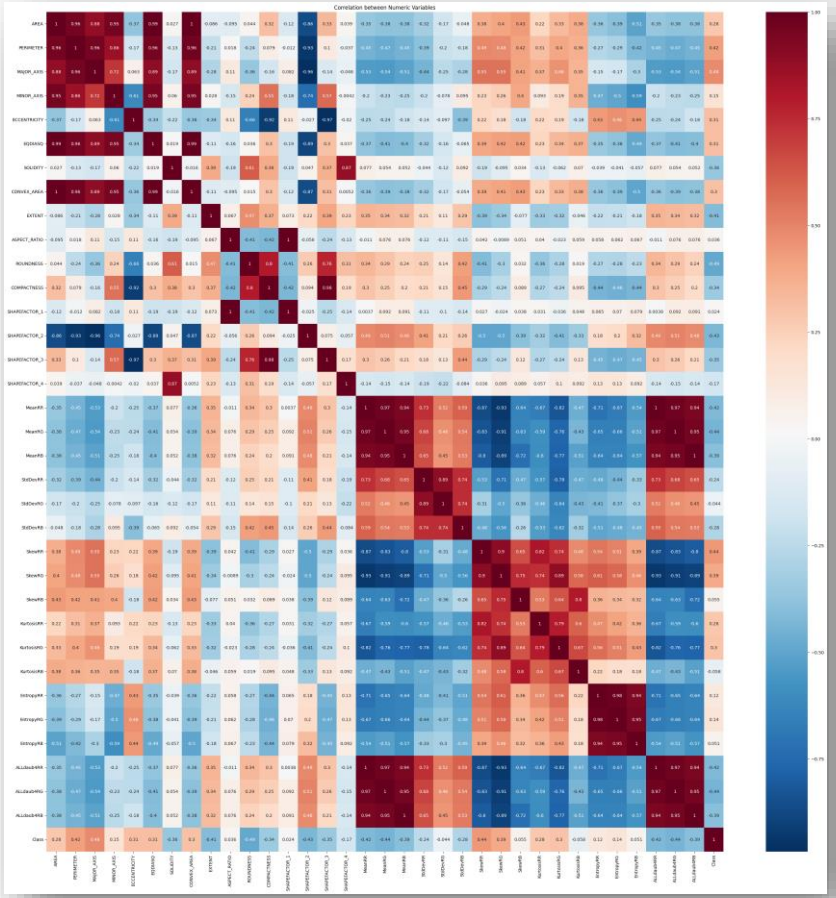

Dengan menggunakan metode pearson correlation, dan threshold korelasi = 0.2, maka ada 24 (dari 34) fitur yang akan digunakan.

'AREA', 'PERIMETER', 'MAJOR_AXIS', 'ECCENTRICITY', 'EQDIASQ', 'SOLIDITY', 'CONVEX_AREA', 'EXTENT', 'ROUNDNESS', 'COMPACTNESS', 'SHAPEFACTOR_2', 'SHAPEFACTOR_3', 'MeanRR', 'MeanRG', 'MeanRB', 'StdDevRR', 'StdDevRB', 'SkewRR', 'SkewRG', 'KurtosisRR', 'KurtosisRG', 'ALLdaub4RR', 'ALLdaub4RG', 'ALLdaub4RB'

DEFINE FITUR YANG TERSELEKSI DAN TARGET (x dan y)

```
X = df[names]
y = df['Class']
```

Kode disamping digunakan untuk memisahkan data. Dimana variable X adalah 24 fitur yang sudah diseleksi sebelumnya. Sedangkan variable y adalah target 'Class', dari dataframe yang digunakan

SPLIT DATA TESTING DAN TRAINING

```
# Menggunakan metode hold out
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, stratify= y , random_state = 42)
print('Jumlah Data train: X', X_train.shape, 'Y', y_train.shape)
print('Jumlah Data test: X', X_test.shape, 'Y', y_test.shape)
```

```
Jumlah Data train: X (718, 24) Y (718,)
Jumlah Data test: X (180, 24) Y (180,)
```

Kode diatas adalah untuk membagi data menjadi data training (X_train, y_train) sebanyak 80% dari data, dan data test (X_test, y_test) sebanyak 20% dari data. Stratify= y, untuk memastikan pembagian data training dan test mempertahankan proporsi kelas target. Sementara random_state = 42, adalah angka seed untuk mengatur ulang randomisasi

SCALLING FEATURE

```
scaler = StandardScaler()
scaler.fit(X_train)

scaler.transform(X_train)
scaler.transform(X_test)
```

```
array([[ 0.28813949,  0.43309537,  0.94580413, ..., -1.56950975,
        -1.35403963, -0.85031796],
       [-1.73246611, -1.97381781, -1.92361164, ...,  1.04582431,
         1.35496905,  1.14620267],
       [-0.01528993,  0.23527772,  0.19510731, ..., -1.5097299 ,
        -1.43518261, -1.45433143],
       ...,
       [ 1.35050573,  0.81057482,  0.31735397, ...,  0.28514666,
         0.28547073, -0.19672219],
       [ 0.07693301,  0.14708301,  0.04128167, ..., -1.74426864,
        -1.56497727, -1.47092058],
       [ 0.27101011,  0.23680377,  0.24339139, ..., -0.82822336,
        -1.27869562, -0.41239037]])
```

Kode disamping bertujuan untuk standarisasi data. Yaitu, untuk memastikan semua fitur dalam dataset memiliki skala yang beragam. Hal ini menjadi penting dilakukan untuk algorithma machine learning yang sensitif terhadap skala fitur.

DEFINISI FUNGSI UNTUK MEMPERCEPAT PROSES ITERASI

```python
def train_evaluate_model(model, X_train, y_train, X_test, y_test):
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)

    accuracy = accuracy_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred, average='weighted')
    precision = precision_score(y_test, y_pred, average='micro')
    recall = recall_score(y_test, y_pred, average='weighted')
    balanced_accuracy = balanced_accuracy_score(y_test, y_pred)

    # Membuat dataframe untuk memvisualisasikan hasil
    eval_df = pd.DataFrame([[accuracy, f1, precision, recall, balanced_accuracy]], columns=['accuracy', 'f1_score', 'precision_score', 'recall_score', 'balanced_accuracy_score'])
    return eval_df
```

- Fungsi train_evaluate_model ini akan membantu mempercepat proses iterasi, Dimana hasil akhirnya nanti adalah untuk mengembalikan hasil evaluasi dalam bentuk dataframe
- model.fit(X_train, y_train), kode untuk melatih model menggunakan data training
- y_pred = model.predict(X_test), kode untuk membuat prediksi label untuk data test menggunakan model yang sudah dilatih
- Accuracy, f1, precision, recall, balanced_accuracy adalah metric evaluasi yang akan dihitung
- Hasil evaluasi itu akan disimpan didalam dataframe
- Mengembalikan dataframe eval_df berisi hasil evaluasi model.

TRAINING DAN EVALUASI LOGISTIC REGRESSION

```
lg = LogisticRegression(max_iter=50000) # nilai max_iter berpengaruh pada hasil testing
results = train_evaluate_model(lg, X_train, y_train, X_test, y_test)
results
results.index = ['LogisticRegression']
results.sort_values(by='f1_score', ascending=False).style.background_gradient(cmap = sns.color_palette("Blues", as_cmap=True))
```

TRAINING DAN EVALUASI DECISION TREE

```
decision_tree = DecisionTreeClassifier()
decision_tree_results = train_evaluate_model(decision_tree,X_train, y_train, X_test, y_test)

decision_tree_results.index = ['DecisionTree']

results = pd.concat([results, decision_tree_results])
results.sort_values(by='f1_score',ascending=False).style.background_gradient(cmap = sns.color_palette("ch:s=-.2,r=.6", as_cmap=True))
```

TRAINING DAN EVALUASI KNEARESTNEIGHBORS

```
KNN = KNeighborsClassifier(n_neighbors=12)
knn = train_evaluate_model(KNN, X_train, y_train, X_test, y_test)
knn.index =['KNearsNeighbors']

results = pd.concat([results, knn])

results.sort_values(by='f1_score',ascending=False).style.background_gradient(cmap = sns.color_palette("ch:s=-.2,r=.6", as_cmap=True))
```

TRAINING DAN EVALUASI RANDOMFORESTCLASSIFIER

```
rfc = RandomForestClassifier()
rfc_result = train_evaluate_model(rfc, X_train, y_train, X_test, y_test)
rfc_result.index = ['RandomForest']

results = pd.concat([results, rfc_result])

results.sort_values(by='f1_score',ascending=False).style.background_gradient(cmap = sns.color_palette("ch:s=-.2,r=.6", as_cmap=True))
```

TRAINING DAN EVALUASI XGBOOST

```
xgboost = xgb.XGBClassifier()
xgboost_result = train_evaluate_model(xgboost, X_train, y_train, X_test, y_test)
xgboost_result.index = ['XGBoost']

results = pd.concat([results, xgboost_result])

results.sort_values(by='f1_score',ascending=False).style.background_gradient(cmap = sns.color_palette("ch:s=-.2,r=.6", as_cmap=True))
```

TRAINING DAN EVALUASI NAIVEBAYES

```
Naive_Bayes = GaussianNB()
Naive_Bayes_result = train_evaluate_model(Naive_Bayes, X_train, y_train, X_test, y_test)
Naive_Bayes_result.index = ['NaiveBayes']

results = pd.concat([results, Naive_Bayes_result])

results.head(6).sort_values(by='f1_score',ascending=False).style.background_gradient(cmap = sns.color_palette("ch:s=-.2,r=.6", as_cmap=True))
```

- Variabel lg, decision_tree, KNN, rfc, xgboost, Naïve_Bayes, adalah variable inisialisasi dari tiap-tiap model algorithma yang digunakan
- Step selanjutnya adalah melatih dan mengevaluasi model menggunakan fungsi yang sudah dibuat sebelumnya, yaitu fungsi train_evaluate_model.
- Hasil dari fungsi ini akan disimpan dalam results. Yang merupakan dataframe yang berisi metrik evaluasi model.
- Selanjutnya indexing, yang bertujuan untuk mengubah indeks baris dalam dataframe menjadi label sesuai dengan algorithma yang digunakan
- Result akan disortir berdasarkan metric f1_score, secara menurun
- Langkah berikutnya adalah memunculkan table dari hasil evaluasi. Tabel akan tampak seperti dibawah.

	accuracy	f1_score	precision_score	recall_score	balanced_accuracy_score
RandomForest	0.900000	0.900593	0.900000	0.900000	0.883574
XGBoost	0.900000	0.897286	0.900000	0.900000	0.863965
LogisticRegression	0.855556	0.855086	0.855556	0.855556	0.819658
NaiveBayes	0.833333	0.834307	0.833333	0.833333	0.790046
DecisionTree	0.827778	0.828248	0.827778	0.827778	0.788325
KNearsNeighbors	0.588889	0.561673	0.588889	0.588889	0.482287

MODEL TRAINING DAN EVALUATION DENGAN MENGGUNAKAN SEMUA FITUR

DEFINE VARIABEL x

```
X_all_features = df.drop('Class',axis=1)
```

SPLIT DATA TRAINING DAN TESTING

```
X_train_all_features, X_test_all_features, y_train, y_test = train_test_split(X_all_features, y, test_size = 0.2, stratify= y , random_state = 42)
print('Jumlah Data train: X', X_train_all_features.shape, 'Y', y_train.shape)
print('Jumlah Data test: X', X_test_all_features.shape, 'Y', y_test.shape)
```

```
Jumlah Data train: X (718, 34) Y (718,)
Jumlah Data test: X (180, 34) Y (180,)
```

SCALING FITUR

```
scaler.fit(X_train_all_features)

scaler.transform(X_train_all_features)
scaler.transform(X_test_all_features)
```

```
array([[ 0.28813949,  0.43309537,  0.94580413, ..., -1.56950975,
        -1.35403963, -0.85031796],
       [-1.73246611, -1.97381781, -1.92361164, ...,  1.04582431,
         1.35496905,  1.14620267],
       [-0.01528993,  0.23527772,  0.19510731, ..., -1.5097299 ,
        -1.43518261, -1.45433143],
       ...,
       [ 1.35050573,  0.81057482,  0.31735397, ...,  0.28514666,
         0.28547073, -0.19672219],
       [ 0.07693301,  0.14708301,  0.04128167, ..., -1.74426864,
        -1.56497727, -1.47092058],
       [ 0.27101011,  0.23680377,  0.24339139, ..., -0.82822336,
        -1.27869562, -0.41239037]])
```

EVALUASI MODEL DENGAN MENGGUNAKAN SEMUA FITUR

```
# Logistic Regression
LogisticRegression_all_features = train_evaluate_model(lg, X_train_all_features, y_train, X_test_all_features, y_test)

LogisticRegression_all_features.index = ['LogisticRegression_all_features']
results = pd.concat([results, LogisticRegression_all_features])


# Decision Tree
DecisionTree_all_features = train_evaluate_model(decision_tree, X_train_all_features, y_train, X_test_all_features, y_test)
DecisionTree_all_features.index = ['DecisionTree_all_features']
results = pd.concat([results, DecisionTree_all_features])


# KNearestNeighbors
KNearsNeighbors_all_features =  train_evaluate_model(KNN, X_train_all_features, y_train, X_test_all_features, y_test)

KNearsNeighbors_all_features.index = ['KNearsNeighbors_all_features']
results = pd.concat([results, KNearsNeighbors_all_features])
```

EVALUASI MODEL DENGAN MENGGUNAKAN SEMUA FITUR

```
# RandomForestClassifier
RandomForest_all_features = train_evaluate_model(rfc,X_train_all_features, y_train, X_test_all_features, y_test)

RandomForest_all_features.index = ['RandomForest_all_features']
results = pd.concat([results, RandomForest_all_features])


# XGBoost
XGBoost_all_features = train_evaluate_model(xgboost,X_train_all_features, y_train, X_test_all_features, y_test)

XGBoost_all_features.index = ['XGBoost_all_features']
results = pd.concat([results, XGBoost_all_features])


# Naive Bayes
Naive_Bayes_all_features = train_evaluate_model(Naive_Bayes,X_train_all_features, y_train, X_test_all_features, y_test)
Naive_Bayes_all_features.index = ['NaiveBayes_all_features']

results = pd.concat([results, Naive_Bayes_all_features])
```

MENAMPILKAN TABEL HASIL EVALUASI

```
results.sort_values(by='f1_score',ascending=False).style.background_gradient(cmap = sns.color_palette("ch:s=-.2,r=.6", as_cmap=True))
```

Kode diatas untuk menampilkan table hasil yang di-sortir berdasarkan nilai f1_score secara descending. Menggunakan fungsi yang memberikan highlight visual pada dataframe dengan warna lebih gelap untuk nilai yang lebih tinggi, dan sebaliknya

	accuracy	f1_score	precision_score	recall_score	balanced_accuracy_score
RandomForest_all_features	0.916667	0.916667	0.916667	0.916667	0.895087
RandomForest	0.900000	0.900593	0.900000	0.900000	0.883574
XGBoost_all_features	0.900000	0.900301	0.900000	0.900000	0.876478
XGBoost	0.900000	0.897286	0.900000	0.900000	0.863965
LogisticRegression	0.855556	0.855086	0.855556	0.855556	0.819658
DecisionTree_all_features	0.838889	0.845346	0.838889	0.838889	0.805450
NaiveBayes	0.833333	0.834307	0.833333	0.833333	0.790046
DecisionTree	0.827778	0.828248	0.827778	0.827778	0.788325
KNearsNeighbors_all_features	0.700000	0.670081	0.700000	0.700000	0.565838
LogisticRegression_all_features	0.616667	0.582460	0.616667	0.616667	0.560714
KNearsNeighbors	0.588889	0.561673	0.588889	0.588889	0.482287
NaiveBayes_all_features	0.555556	0.541998	0.555556	0.555556	0.450281

KESIMPULAN

- Dari 6 algorithma machine learning yang digunakan untuk klasifikasi jenis buah kurma, random forest dan Xgboost, adalah algoritma dengan hasil evaluasi yang paling baik, yaitu >= 90%
- Algoritma RandomForest, XGBoost, Decision Tree dan KNearestNeighbors, justru memperoleh hasil evaluasi yang lebih baik saat menggunakan semua fitur. Sebaliknya untuk algoritma Logistic Regression dan Naïve Bayes.
- Algoritma RandomForest, XGBoost, dan Decision Tree, memiliki hasil evaluasi yang mendekati stabil baik saat menggunakan semua fitur maupun tidak. Sebaliknya untuk Algoritma Logistic Regression, Naïve Bayes dan KNearestNeighbors.
- Dari 6 fitur yang digunakan, algoritma KNearestNeighbors memperoleh hasil yang paling rendah baik saat menggunakan semua fitur maupun tidak.


Thanks!